

Proyecto de Cátedra IAR105 Primer Avance:

Bases documentales de sistema CAD para detección de tumores Cerebrales

Erick Rodriguez
Escuela de Biomédica
San Salvador, El Salvador
RB220977

Gabriela Apaza
Escuela de Biomédica
San Salvador, El Salvador
SA190661

Rafael Najarro
Escuela de Computación
San Salvador, El Salvador
NC212543

Alberto Rojas
Escuela de Biomédica
San Salvador, El Salvador
RR190510

Abstract— The evolution of the computer - Aided Diagnosis (CAD) system for brain tumor detection has been driven by advances in medical imaging and artificial intelligence. This paper presents the development of a deep learning-based prototype for the classification of brain magnetic of a deep learning-based prototype for the classification of brain magnetic resonance imaging (MRI) scans into four categories: glioma, meningioma, pituitary tumor, and no tumor. The study leverages a public dataset comprising over 12,000 contrast-enhanced T1-weighted MRI images, organized into training and test subsets. A convolutional neural network (CNN) architecture is designed and implemented to perform automatic feature extraction and classification, eliminating the need for manual feature engineering. The proposed system includes a web - based graphical interface that allows users to upload new MRI images and obtain a predicted class along with associated confidence probabilities. Model performance is evaluated using standard metrics such as accuracy, precision, recall, and F1 score. Although the prototype is intended for academic and research purposes and does not replace clinical diagnosis, it demonstrates the viability of deep learning techniques for automated brain tumor classification, offering a scalable and accessible tool for preliminary image analysis.

I. INTRODUCCIÓN

La evolución de los Sistemas de Diagnóstico Asistido por Computadora (CAD) para la detección de tumores cerebrales ha dependido de dos modalidades de imagen complementarias: la Resonancia Magnética (MRI) y la Tomografía Axial Computarizada (TAC). La MRI destaca por su elevada resolución de contraste en tejidos blandos, por lo que facilita la identificación de bordes infiltrativos y la caracterización tisular detallada. Por su parte, la TAC constituye la modalidad de primera línea en servicios de urgencias debido a su alta velocidad de adquisición, menor costo operativo y capacidad superior para detectar calcificaciones, erosión ósea y hemorragias agudas asociadas al tumor.

II. MARCO DOCUMENTAL

A. Antecedentes

El desarrollo histórico de los sistemas CAD para neuroimagen se divide en dos grandes etapas metodológicas: Los sistemas basados en reglas e ingeniería características (Machine Learning Clásico y Deep Learning).

Entre 1990 y 2010, el procesamiento dependía por completo del diseño manual de algoritmos. El flujo de trabajo requería aislar la bóveda craneal mediante un filtrado de densidad (Skull Stripping), segmentar la zona sospechosa y extraer descripciones matemáticas de forma simetría y textura (como las matrices GLCM). Finalmente, estos datos alimentaban modelos estadísticos o clasificadores como Máquinas de Vectores de Soporte (SVM) y Bosques Aleatorios. La principal limitación de esta etapa radicaba en su rigidez, por ejemplo, si la imagen presentaba artefactos, variaciones de contraste o ruido técnico, el algoritmo fallaba al no poder adaptar sus reglas.

Posteriormente, a partir de 2012, la capacidad de cálculo de las unidades GPU y la disponibilidad de repositorios digitales permitieron la adopción de Redes Neuronales Convolucionales (CNN). Estas arquitecturas eliminaron la necesidad de diseñar descripciones a mano. El modelo aprende por sí mismo las jerarquías visuales relevantes (bordes, texturas, formas compuestas, etc) directamente a partir de las imágenes de entrada. En neuroimagen, este avance permitió procesar arreglos bidimensionales (cortes individuales) y volúmenes tridimensionales completos, abriendo el paso a la segmentación automática de tumores.

B. Tipos de modelos de aprendizaje automático y sus diferencias

Para el diseño del núcleo de procesamiento del software CAD, existen tres familias principales de modelos en la literatura actual. Las diferencias técnicas entre cada opción definen los requerimientos de cómputo, el volumen de datos necesario y la

complejidad de la implementación, entre ellos destacan:

- **Modelos de Clasificación Superficial (SVM, Random Forest, k-NN)**

Procesan vectores de datos tabulares derivados de la imagen, como métricas de textura, intensidad media de Hounsfield, contraste MRI, área, etc.

No reciben imagen directamente, exigen una capa previa de extracción manual de características.

Requieren un conjunto de datos pequeños y muy pocos recursos computacionales, sin embargo, su precisión cae ante diferencias causadas por la calidad de la imagen de entrada. Además, no ofrece una delimitación visual del tumor.

- **Redes Convolucionales para Clasificación y Detección (ResNet, EfficientNet, YOLO).**

Reciben la imagen en matriz (píxeles o vóxeles) y aplican filtros convolucionales en capas profundas para extraer patrones espaciales.

Determinan si existe un tumor en la imagen (clasificación) y pueden ubicar la lesión mediante una caja delimitadora. Tienen una amplia capacidad de generalización y procesan imágenes rápidamente. Su limitación es que no entregan la forma exacta del contorno tumoral, solo su presencia o ubicación aproximada.

- **Redes de Segmentación Semántica (U-Net, V-Net, Swin UNETR)**

Utilizan arquitecturas del tipo codificador-decodificador. Reducen la imagen para extraer contexto y luego la reconstruyen para clasificar cada píxel o vóxel individualmente.

Generan una máscara binaria o multiclase para delimitar el contorno real del tumor, el tejido sano y el edema.

Proporcionan la información más útil para la planificación clínica y el cálculo de volumen tumoral. Como desventaja, demandan un costo computacional elevado y requieren conjuntos de datos anotados píxel a píxel por especialista.

III. OBJETIVOS

A. Objetivo general

Desarrollar un prototipo funcional basado en deep learning que clasifique imágenes de resonancia magnética cerebral en cuatro categorías (Glioma, Meningioma, Tumor pituitario y Sin tumor), utilizando un dataset público e implementar una interfaz gráfica que permita cargar nuevas imágenes y obtener una predicción con su probabilidad asociada por clase.

B. Objetivos específicos

- Analizar y preparar el dataset seleccionado para su utilización en un modelo de clasificación de imágenes.
- Aplicar técnicas de preprocesamiento y transformación de imágenes para mejorar la consistencia de los datos.
- Diseñar e implementar un modelo de aprendizaje profundo para la clasificación de imágenes
- Implementar una interfaz web que permita cargar una imagen de resonancia magnética y visualizar la clase

predicha junto con el nivel de confianza de cada categoría.

- Evaluar el desempeño del modelo mediante métricas como accuracy, precision, recall y F1-score.

IV. ALCANCES Y LIMITACIONES

A. Alcances

- Clasificar las imágenes en las cuatro categorías definidas por el dataset.
- Implementar una solución experimental que permita ingresar una imagen y obtener la clase predicha.
- Comparar el desempeño del modelo mediante métricas de evaluación necesarias.

B. Limitaciones

- El modelo dependerá de la calidad, distribución y características de las imágenes presentes en el dataset.
- La solución estará limitada a las cuatro categorías disponibles del dataset.
- El sistema tendrá fines académicos y de investigación, por lo que no sustituye la valoración de un profesional médico.
- El prototipo desarrollado no será validado clínicamente ni desplegado en un entorno hospitalario real.

V. DATASET SELECCIONADO Y JUSTIFICACIÓN

Para el entrenamiento del modelo se realizó una investigación y evaluación de diferentes conjuntos de datos (datasets) relacionados con imágenes de resonancia magnética (MRI) del cerebro. La selección se llevó a cabo considerando diferentes criterios, entre ellos la cantidad de imágenes disponibles, la distribución de las clases, la organización de los datos y su utilidad para las etapas de entrenamiento y evaluación del modelo.

Entre las principales alternativas consideradas se encuentra el Brain Tumor MRI Dataset [1], disponible en la plataforma Kaggle. Este conjunto de datos fue considerado inicialmente como una de las principales opciones debido a la cantidad de imágenes disponibles y a la distribución equilibrada de las clases. De acuerdo con la información proporcionada por su autor, el conjunto contiene 7,200 imágenes de resonancia magnética cerebral, clasificadas en cuatro categorías: glioma, meningioma, pituitary y no tumor. Además, se encuentra dividido en conjuntos de entrenamiento y prueba, con una distribución equilibrada entre las diferentes categorías.

La distribución de las imágenes de este conjunto de datos es la siguiente:

Conjunto de entrenamiento:

- Glioma: 1,400 imágenes.
- Meningioma: 1,400 imágenes.
- Pituitary: 1,400 imágenes.
- No tumor: 1,400 imágenes.

Conjunto de prueba:

- Glioma: 400 imágenes.
- Meningioma: 400 imágenes.
- Pituitary: 400 imágenes.
- No tumor: 400 imágenes.

Otra de las alternativas evaluadas fue el conjunto de datos Brain Tumor Classification (MRI) [2], disponible también en Kaggle. Este conjunto fue considerado debido a su utilización para tareas de clasificación de tumores cerebrales mediante imágenes de

resonancia magnética y a que contempla cuatro categorías de clasificación. El dataset ha sido empleado como recurso para el desarrollo de modelos de aprendizaje automático y aprendizaje profundo orientados a la detección y clasificación de tumores cerebrales.

Sin embargo, al comparar las diferentes alternativas disponibles, se determinó que este conjunto presentaba una cantidad de imágenes inferior a la de otras opciones consideradas, por lo que se continuó con la evaluación de otros conjuntos de datos que permitieran disponer de una mayor cantidad de información para el entrenamiento del modelo.

Finalmente, el conjunto de datos seleccionado fue el Brain Tumor MRI Dataset (Glioma, Meningioma, Pituitary, No Tumor) [3], disponible en la plataforma Mendeley Data. La selección se realizó principalmente debido a su mayor cantidad de imágenes y a que estas se encuentran previamente procesadas y clasificadas en cuatro categorías: glioma, meningioma, pituitary y no tumor. El conjunto contiene 12,064 imágenes de resonancia magnética cerebral T1 ponderadas con contraste y se encuentra organizado en un 80 % para entrenamiento y 20 % para pruebas.

De acuerdo con la distribución utilizada para el desarrollo del modelo, los datos de entrenamiento se encuentran conformados de la siguiente manera:

Datos de entrenamiento (80 %):

- Glioma: 3,018 imágenes.
- Pituitary: 2,504 imágenes.
- Meningioma: 2,183 imágenes.
- No tumor: 1,945 imágenes.

Por otra parte, el conjunto destinado a la evaluación del modelo se encuentra distribuido de la siguiente manera:

Datos de prueba (20 %):

- Glioma: 755 imágenes.
- Pituitary: 546 imágenes.
- Meningioma: 626 imágenes.
- No tumor: 487 imágenes.

Esta distribución permite contar con una cantidad considerable de imágenes para el entrenamiento del modelo, al mismo tiempo que mantiene un conjunto independiente para evaluar su desempeño. La utilización de un mayor volumen de datos permite proporcionar al modelo una mayor variedad de ejemplos durante el proceso de aprendizaje y, posteriormente, comprobar su capacidad para clasificar imágenes que no fueron utilizadas durante el entrenamiento.

En consecuencia, el conjunto de datos de Mendeley Data fue seleccionado como la alternativa más adecuada para el desarrollo del modelo, debido principalmente a su cantidad de imágenes, su clasificación en cuatro categorías y la separación previamente establecida entre los datos de entrenamiento y prueba. Estas características permiten disponer de una base de datos adecuada para el desarrollo de un modelo de clasificación de tumores cerebrales mediante técnicas de aprendizaje profundo.

VI. ARQUITECTURA GENERAL PROPUESTA

La arquitectura propuesta define un flujo de procesamiento que abarca desde la adquisición y preparación de las resonancias magnéticas cerebrales hasta el entrenamiento de un modelo de aprendizaje profundo para su clasificación. Finalmente, dicho modelo se integra en una aplicación web desarrollada en Streamlit, lo que permite a los usuarios cargar nuevas imágenes y obtener de manera directa su clasificación dentro de una de las cuatro categorías establecidas.

A continuación se presenta un diagrama que explica los pasos a

seguir:




Fig 1. Diagrama de arquitectura general propuesta

A. Preprocesamientos y entrada de datos

En términos generales, el preprocesamiento busca acondicionar y estructurar los datos para garantizar su calidad antes del análisis. En este trabajo, el proceso se enfoca en las imágenes de resonancia magnética (MRI), abarcando la verificación de su calidad, la estandarización de formatos y la aplicación de las transformaciones requeridas previo a su ingreso al modelo. [4]

Enfocándose en el trabajo, a partir de un dataset de resonancias magnéticas cerebrales que abarca cuatro categorías (glioma, meningioma, tumor pituitario y sin tumor), se aplican técnicas de preprocesamiento como redimensionamiento y normalización para homogeneizar las imágenes de entrada. Además, se integran transformaciones de imagen que aumentan la variabilidad de los datos durante el entrenamiento del modelo.

B. Modelo de Deep Learning

Para la etapa de clasificación, utilizaremos modelos de aprendizaje profundo basados en redes neuronales convolucionales (CNN), una técnica ampliamente validada en el análisis de imágenes médicas. Evaluaremos y compararemos tres alternativas: una CNN tradicional, ResNet y EfficientNet. Estas redes recibirán las imágenes previamente preparadas para clasificarlas en una de las cuatro categorías de estudio: glioma, meningioma, tumor pituitario

o no tumor. Al final, compararemos los resultados de cada modelo para elegir la arquitectura con mejor rendimiento. Durante la preparación de las imágenes y el entrenamiento, aplicaremos técnicas de aumento de datos (data augmentation). Esto se debe a que conseguir grandes colecciones de imágenes médicas suele ser complicado por temas de privacidad y el costo que implica etiquetarlas [5]. Con el aumento de datos aplicamos transformaciones a las imágenes que ya tenemos, lo que nos permite ampliar la variedad del conjunto de entrenamiento sin necesidad de recolectar nuevas muestras. Además, esta técnica ayuda a que el modelo no se memorice las imágenes (regularización) y nos permite reforzar las clases que tengan menos datos [5].

C. Entrenamiento y evaluación

Durante la etapa de entrenamiento, ajustaremos los modelos con el conjunto de datos asignado para que aprendan las características clave de cada una de las cuatro categorías. Posteriormente, evaluaremos su desempeño utilizando un grupo de imágenes completamente independiente que el modelo no haya visto durante el aprendizaje; esto nos permitirá medir de forma real su capacidad de generalización. La necesidad de esta separación rigurosa se debe a que la literatura evidencia que la mayoría de los algoritmos de aprendizaje profundo en radiología sufren una caída en su rendimiento cuando se prueban con datos distintos a los de entrenamiento, reportando en muchos casos reducciones sustanciales en su precisión [6].

Para evaluar el comportamiento final de cada arquitectura y comparar su rendimiento de manera objetiva, utilizaremos las métricas de accuracy, precisión, recall y F1-score. Además, complementaremos el análisis con matrices de confusión para identificar con claridad qué clases o categorías presentan mayor nivel de confusión entre sí.

D. Predicción de nuevos casos

Para la etapa final de uso e interacción, desarrollaremos una interfaz web interactiva. La plataforma permitirá a los usuarios cargar una nueva imagen de resonancia magnética para su análisis. Antes de ingresar al modelo seleccionado, la nueva imagen pasará exactamente por el mismo procedimiento de preparación (redimensionamiento, normalización y estandarización) aplicado durante la fase de entrenamiento. Mantener este flujo de preprocesamiento riguroso resulta indispensable, ya que la literatura en visión por computadora demuestra que la estandarización previa de los datos es determinante para que los modelos de deep learning mantengan su precisión y logren clasificar tumores cerebrales de forma confiable [8].

Una vez procesada la imagen, el sistema no solo mostrará la categoría de diagnóstico predicha, sino también el desglose de las probabilidades asociadas a cada una de las clases, brindando un resultado transparente y fácil de interpretar para el usuario.

VII. TECNOLOGÍAS A UTILIZAR

TABLA 1
TECNOLOGÍAS PROPUESTAS PARA EL DESARROLLO

Tecnología	Uso dentro del proyecto
------------	-------------------------

Python	Lenguaje principal para el procesamiento de datos, desarrollo y entrenamiento del modelo de clasificación.
Tensor Flow / Keras	Desarrollo, entrenamiento y evaluación de la red neuronal convolucional.
OpenCV	Procesamiento, transformación y manipulación de imágenes médicas
NumPy	Manipulación de matrices, arreglos numéricos y operaciones aritméticas sobre los datos.
scikit-learn	Cálculo de métricas de evaluación como accuracy, precision, recall y F1-score.
Pandas	Manipulación, organización y análisis de los datos asociados al dataset y resultados del modelo.
Streamlit	Desarrollo de una interfaz web para permitir al usuario cargar una imagen médica y visualizar la clasificación generada por el modelo.
Matplotlib	Generación de gráficas para visualizar el entrenamiento, desempeño del modelo y resultados.
Google Colab	Entorno para desarrollar, ejecutar y probar el modelo.
Git / GitHub	Control de versiones del proyecto y colaboración con los integrantes.

Fuente: Elaboración propia

VIII. CRONOGRAMA DE ACTIVIDADES

Sistema CAD para detección de tumores cerebrales

ID	Actividad	Pred eces or	Duraci ón (Días)
FASE 1. Preparación del entorno y datos			
1.1	Configuración del entorno de desarrollo	-	2
1.2	Descarga y exploración del dataset	1.1	2
1.3	Análisis exploratorio de	1.2	3

datos (EDA)				interfaz web				
FASE 2. Preprocesamiento y aumento de datos				5.1	Diseño de la interfaz en streamlit		4.6	3
2.1	Diseño del pipeline de preprocesamiento	1.3	2	5.2	Integración del modelo seleccionado		4.6, 5.1	3
2.2	Implementación de preprocesamiento	2.1	3	5.3	Desarrollo de visualización de probabilidades		5.2	2
2.3	Implementación de técnicas de aumento de datos	2.1	2	5.3	Pruebas de la interfaz con casos reales		5.3	3
2.4	Validación del pipeline de datos	2.2,2.3	2	FASE 6. Documentación y entregables				
FASE 3. Diseño e implementación de modelos				6.1	Elaboración de informe final		5.4	5
3.1	Implementación de CNN tradicional	2.4	4	6.2	Preparación de presentación		5.4	3
3.2	Implementación de ResNet	2.4	4	6.3	Subida a GitHub		5.4	2
3.3	Implementación de EfficientNet	2.4	4	6.4	Correcciones finales		6.1, 6.2, 6.3	2
3.4	Configuración de hiperparámetros	2.4	2	FASE 7. Cierre				
FASE 4. Entrenamiento y evaluación				7.1	Entrega final		6.4	1
IX. ASIGNACIÓN DE ACTIVIDADES								
4.1	Entrenamiento de CNN tradicional	3.1, 3.4	4	Integrante	Actividades principales		Rol de equipo	
4.2	Entrenamiento de ResNet	3.2, 3.4	4					
4.3	Entrenamiento de EfficientNet	3.3, 3.4	4	Erick Rodriguez	Exploración del dataset, validación clínica, liderazgo en informe final.		Coordinador / Especialista en datos médicos	
4.4	Evaluación con conjunto de prueba	4.1, 4.2, 4.3	3	Gabriela Apaza	Análisis exploratorio, matrices de confusión, liderazgo en presentación.		Analista de resultados / Documentación	
4.5	Generación de matrices de confusión	4.4	2	Alberto Rojas	Diseño de preprocesamiento, pruebas de interfaz, apoyo en documentación.		Especialista en procesamiento de imágenes	
4.6	Comparación y selección del mejor modelo	4.4, 4.5	2	Rafael Najarro	Configuración de entorno, implementación de modelos, interfaz web, GitHub.		Desarrollador principal / Deep Learning	
FASE 5. Implementación de la								

X. CONCLUSIONES

El desarrollo de un prototipo de sistema de diagnóstico asistido por computadora (CAD) para la clasificación de tumores cerebrales mediante imágenes de resonancia magnética representa una aplicación relevante del aprendizaje profundo en el ámbito de la ingeniería biomédica. La selección de un conjunto de datos amplio y estructurado, junto con la implementación de técnicas de preprocesamiento, aumento de datos y arquitecturas de redes neuronales convolucionales, proporciona una base sólida para construir un modelo capaz de diferenciar las cuatro categorías establecidas: glioma, meningioma, tumor pituitario y ausencia de tumor.

Asimismo, la incorporación de una interfaz web desarrollada en Streamlit busca facilitar la interacción con el modelo, permitiendo realizar predicciones de manera sencilla y mostrar el nivel de confianza asociado a cada clasificación. Aunque el prototipo tiene un enfoque académico y no pretende sustituir el criterio clínico ni ha sido validado en un entorno hospitalario, el proyecto evidencia el potencial de las técnicas de inteligencia artificial para apoyar el análisis preliminar de imágenes médicas y contribuir al desarrollo de herramientas que, en el futuro, puedan complementar el proceso de diagnóstico en neuroimagen.

XII. GLOSARIO

CAD: (sistema de diagnóstico asistido por computadora) hace referencia a sistema software que asiste a los médicos en la interpretación de imágenes médicas. Los sistemas CAD utilizan algoritmos de inteligencia artificial para detectar y clasificar tumores cerebrales a partir de imágenes de resonancia magnética o tomografía, ofreciendo una segunda opinión o un análisis preliminar que apoya la toma de decisiones clínicas.

MRI: (Magnetic resonance imaging) modalidad de imagen médica que utiliza campos magnéticos intensos y ondas de radio para generar imágenes detalladas.

Machine Learning: Aprendizaje automático, subcampo de la inteligencia artificial que permite a los sistemas aprender patrones y hacer predicciones a partir de datos sin necesidad de ser programados explícitamente para cada tarea.

Deep Learning: Rama especializada del aprendizaje automático basada en redes neuronales artificiales con múltiples capas. A diferencia del machine learning clásico, los modelos de deep learning aprenden jerarquías de características visuales directamente de los datos brutos.

ROI: (Region Of Interest) Es el área de interés para el análisis de imagen.

Matriz GLCM: (Gray Level Co-occurrence Matrix) Es un método estadístico de segundo orden, utilizado para analizar y cuantificar la textura de una imagen digital en escala de grises por la frecuencia de aparición de sus píxeles en una ROI.

SMV: (Support Vector Machine) Algoritmo de aprendizaje supervisado utilizado para clasificación y regresión. Su objetivo es encontrar el hiperplano óptimo que maximice el margen de separación entre distintas clases en el espacio de características.

Bosques Aleatorios: (Random Forest) Algoritmo de aprendizaje supervisado en ensamble basado en la combinación de múltiples árboles de decisión. Funciona entrenando cada árbol e interpolando la respuesta de éstos árboles.

k-NN: Es un algoritmo de aprendizaje automático supervisado utilizado para clasificación y regresión. Su funcionamiento se basa

en asignar una etiqueta a un nuevo dato según la clase mayoritaria.

Intensidad Media de Hounsfield: Es un valor numérico que representa la densidad media de los tejidos en una imagen de tomografía axial computarizada (TAC).

F1-Score: Es una métrica de evaluación para modelos de clasificación que representa la media armónica entre la precisión y la sensibilidad. Proporciona una medida balanceada del desempeño del algoritmo en una escala de 0 a 1 (o de 0 al 100%).

REFERENCIAS

- [1] M. Nickparvar, "Brain Tumor MRI Dataset," Kaggle, 2026. [Online]. Available: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>. [Accessed: Aug. 13, 2026].
- [2] S. Bhuvaji, "Brain Tumor Classification (MRI)," Kaggle, 2026. [Online]. Available: <https://www.kaggle.com/datasets/sartajbhuvaji/brain-tumor-classification-mri>. [Accessed: Aug. 13, 2026].
- [3] M. I. K. Hira, M. S. Hossain, M. M. A. Bithee, U. S. Sara, M. M. Hasan, A. Al Towsif, and M. K. Ahmed, "Brain Tumor MRI Dataset (Glioma, Meningioma, Pituitary, No Tumor)," Mendeley Data, ver. 4, 2025, doi: 10.17632/zwr4ntf94j.4.
- [4] B. Malley, D. Ramazzotti, and J. T. Wu, "Data Pre-processing," in *Secondary Analysis of Electronic Health Records*, Cham, Switzerland: Springer, 2016, ch. 12. doi: 10.1007/978-3-319-43742-2_12.
- [5] M. Nalepa, M. Marcinkiewicz, and M. Kawulok, "Data augmentation for medical imaging: A systematic literature review," *Computers in Biology and Medicine*, vol. 152, p. 106388, 2023.
- [6] A. C. Yu, B. Mohajer, and J. Eng, "External Validation of Deep Learning Algorithms for Radiologic Diagnosis: A Systematic Review," *Radiology: Artificial Intelligence*, vol. 4, no. 3, p. e210064, 2022.
- [8] T. K. Wan and K. H. K. Chan, "Leveraging Deep Learning Model for Computer Vision-Based Brain Tumor Classification in 3D MRI Brain Images," in 2024 46th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Orlando, FL, USA, 2024, pp. 1–4. doi: 10.1109/EMBC53108.2024.10782201.